

Цель – разработать алгоритм, который надежно и быстро может идентифицировать “скрытых предпринимателей” в транзакционных данных



Описание таблиц транзакционных данных по 2 сегментам

Business Cardholders		Consumer Cardholders	
25K	активных карт	80K	активных карт
~3M	транзакций	~10M	транзакций

№	Название колонки	Бизнес-определение
1	transaction_date	Календарная дата совершения транзакции. Примечания: диапазон 1 октября 2025 – 31 марта 2026
2	transaction_timestamp	Бизнес-определение: полная дата и время совершения транзакции, с точностью до секунды
3	transaction_amount_kzt	Сумма транзакции в тенге
4	mcc	Merchant Category Code – четырёхзначный код ISO 18245, определяющий сферу деятельности торговца
5	merchant_id	Идентификатор конкретного торговца, у которого прошла транзакция. Формат MER_#####; связывается с merchants_reference.paquelet для получения названия/страны/MCC
6	channel	Способ оплаты карты: онлайн либо офлайн (физическое присутствие)
7	bank_name	Банк-эмитент карты
8	country	Страна, в которой прошла транзакция (страна транзакции/эквайрера)
9	card_number	16-значный номер карты
10	card_tier	Продуктовый уровень карты
11	tokenized	Была ли оплата проведена через токенизированный кошелек (Apple Pay / Samsung Pay)
12	is_recurring	Является ли списание регулярным платежом, инициированным торговцем (подписка или авто-биллинг платформы)



Описание таблицы по справочнику MCC-кодов

Merchants

~2K мерчантов

№	Название колонки	Бизнес-определение
1	merchant_id	Уникальный идентификатор торговца — ключ, по которому таблица связывается с транзакциями. Примечания: формат MER_####. Это тот же идентификатор, что встречается в каждой строке файлов business_cards.parquet и consumer_cards.parquet
2	merchant_name	Название торговца
3	mcc	Merchant Category Code (ISO 18245) — категория деятельности данного торговца
4	merchant_country	Страна регистрации/биллинга торговца — где торговец «прописан». Например, Google Ads → Ирландия, AWS → США, Magnum → Казахстан. Важно: это отличается от столбца country в транзакциях, который означает страну совершения операции.
5	recurring_capable	Способен ли торговец выставлять регулярные платежи (подписки, авто-биллинг)



Критерий оценивания работы

№	Критерий	Комментарии	Вс
1	ML Solution Quality	• Есть обоснование выбора модели • Корректное обучение модели • Использован train/test split или validation • Применен подбор параметров или сравнение моделей	25%
2	Metrics & Results	• Использованы подходящие метрики оценки (min. confusion matrix) • Метрики интерпретированы корректно • Выводы подтверждаются данными • Результаты показывают эффективность решения	20%
3	Data Processing & Feature Engineering	• Корректно проведена обработка данных • Обработаны пропуски и выбросы • Описание процесса построения признаков и обоснование их выбора • Feature engineering связан с бизнес-задачей	15%
4	Correctness & Functionality	• Решение запускается без ошибок • Правильное понимание задачи • Модель решает поставленную проблему	10%
5	Code Quality & Structure	• Код чистый и читаемый • Понятные названия переменных • Есть комментарии	10%
6	Creativity & Solution Depth	• Оригинальность решения • Интересные гипотезы и подходы • Обоснование бизнес-цели • Нестандартные и продуманные идеи	10%
7	Documentation & Explainability	• Поведение модели объяснимо • Указаны ограничения решения • Есть выводы и рекомендации	5%
8	Reproducibility	• Решение можно повторно запустить • Указаны необходимые библиотеки и файлы • Шаги описаны последовательно	5%

100%



В рамках проекта ожидаем от вас 2 материала: python-код и презентация



Технический код

Воспроизводимый python-код с комментариями и структурированным решением задачи



PowerPoint презентация

Презентация, объясняющая методологию выбора модели, логику и обоснование выбора фичей, финальные рекомендации¹

¹. Рекомендуется не ограничиваться исключительно содержанием данной презентации, а при необходимости дополнять её другими материалами, которые вы считаете релевантными

